01 · Задачи машинного обучения

15.09.2026 · Постановка, kNN, признаки, оценка качества.

Задачи машинного обучения · 15.09.2026 · Постановка, kNN, обобщение · Опорные фрагменты: 00:25–00:55; 01:05–01:35.

Данные → модель → критерий

Выборка $D = \{(x_i, y_i)\}_{i=1}^{n}$, где $x_i \in \mathbb{R}^d$ — признаки объекта, y_i — целевая переменная. Матрица $X \in \mathbb{R}^{n \times d}$: **объекты по строкам, признаки по столбцам**. Изображение 28×28 превращается в вектор из 784 чисел; RGB-изображение 100×100 — из 30 000.

Регрессия: числовой ответ, важна величина ошибки. **Классификация:** выбор одного из конечного набора классов. Счётчик проданных товаров дискретен, но обычно задаёт регрессию: ошибка на 1 и на 100 различна. Кластеризация ищет группы без известных меток; это другая постановка.

Обучение имеет смысл после выбора семейства $\mathcal{M}$ и функции потерь ℓ:

$$\hat{f} \in \arg\min_{f \in \mathcal{M}} \frac{1}{n} \sum_{i=1}^{n} \ell(y_i, f(x_i)).$$

Параметры оцениваются внутри обучения; **гиперпараметры** задают его конфигурацию и выбираются внешней процедурой: k у kNN, степень полинома, сила регуляризации.

Параметрическая модель имеет фиксированное семейство f_θ и конечномерный θ. У непараметрической модели сложность представления может расти с выборкой. Непараметрическая ≠ «без настроек»: kNN имеет k, KDE — ширину окна.

Почему ответ случаен

Наблюдаются не все факторы; есть шум измерений и случайность среды. Поэтому одинаковым наблюдаемым x могут соответствовать разные Y. Задача — восстановить закономерность, а не буквально запомнить все метки.

> **«Лучшая модель» не определена без семейства, критерия и данных проверки.** Качество на обучении не отвечает на вопрос о новых объектах.

Базовая проверка качества

$$\text{Accuracy} = \frac{1}{m} \sum_{i=1}^{m} \mathbb{1}\{\hat{y}_i = y_i\}.$$

Вычислять на объектах, не участвовавших в обучении. Малый train-loss при большом validation-loss — признак переобучения; большой loss в обоих случаях — недообучение либо недостаток признаков.

Разделять **train** для оценки параметров, **validation** для выбора настроек, **test** для финальной оценки. Повторный подбор по test превращает его в validation. Случайное разбиение уместно лишь при соответствующей природе данных; связанные объекты и временные данные требуют особого разбиения.

k ближайших соседей

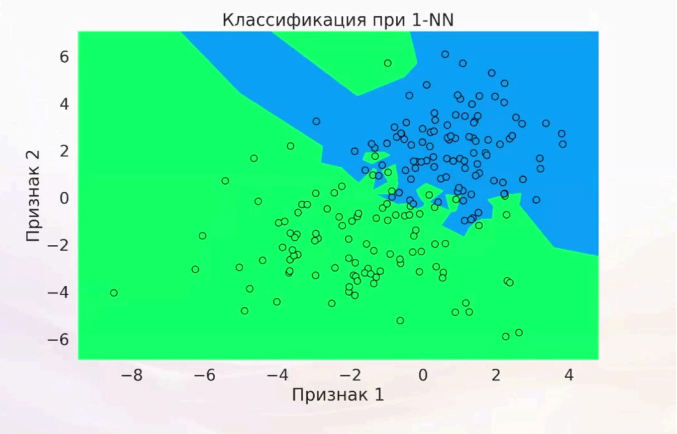
Пусть $N_k(x)$ — индексы k ближайших объектов по расстоянию ρ. Классификация — голосование; регрессия — усреднение:

$$\hat{y}(x) = \arg\max_{c} \sum_{i \in N_k(x)} \mathbb{1}\{y_i = c\},$$

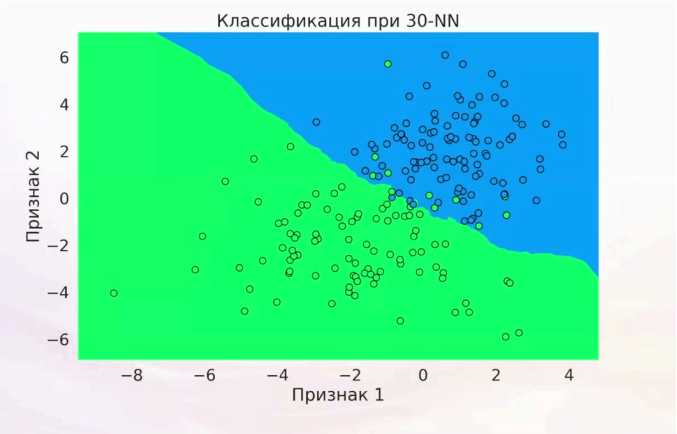
$$\hat{f}(x) = \frac{1}{k} \sum_{i \in N_k(x)} y_i.$$

Для весов $w_i(x) \geq 0$ голосование и среднее взвешиваются. Например, $w_i = \frac{1}{\rho(x, x_i)}$; при нулевом расстоянии нужно отдельно обработать совпадающие точки. Правило разрешения равенства голосов тоже часть алгоритма.

Малое k**:** локальность, сложная граница, чувствительность к шуму. **Большое** k**:** сглаживание, меньше случайных колебаний, риск недообучения. При $k = n$ получаем глобальное большинство или среднее; $k > n$ недопустимо.



1-NN: локальные «островки» и сложная граница. · 15.09 · 00:43:00



30-NN: более гладкая граница на тех же данных. · 15.09 · 00:45:00

Цена простоты

При полном переборе хранение $O(nd)$; вычисление расстояний для одного нового объекта $O(nd)$. Выбор k лучших добавляет стоимость отбора; полная сортировка — $O(n \log n)$, но сортировать всё необязательно. Обучение обычно сводится к сохранению данных; индекс может потребовать дополнительной работы. Быстрое обучение не означает быстрый inference.

Признаки и рабочий процесс · 15.09.2026 · Бейзлайны, масштабирование, EDA, KDE · Фрагменты: 01:35–02:15; 02:20–03:04.

Расстояния зависят от представления

Евклидова мера $\rho(x, z) = \sqrt{\sum_j (x_j - z_j)^2}$ складывает вклад координат. Признак в рублях может подавить признак в годах только из-за масштаба. Единицы измерения нельзя принимать за важность признака. **StandardScaler:** $z_j = \frac{x_j - \mu_j}{s_j}$. **MinMaxScaler:** $z_j = \frac{x_j - a_j}{b_j - a_j}$.

Все статистики вычислять **по train**. Для постоянного столбца нужна обработка нулевого знаменателя. Стандартизация не делает распределение нормальным; обе схемы чувствительны к выбросам.

> `fit_transform(train)` → `transform(validation/test)`. Нельзя заново обучать scaler, imputer или encoder на test. `Pipeline` фиксирует порядок; `ColumnTransformer` разделяет обработку типов признаков.

Проклятие размерности

При большом числе слабых или шумовых координат «ближайший» может перестать быть содержательно близким. Расстояния концентрируются, а для заполнения локальных окрестностей нужно всё больше данных. Неинформативные признаки ухудшают kNN; важны отбор, преобразование и предметно осмысленная мера. Одинаковое число координат ещё не означает одинаковую сложность задачи.

Бейзлайн — обязательная точка отсчёта

Сравнивать сложную модель с простым решением или текущим бизнес-правилом. Для классификации с частотами классов π_c:

- постоянный самый частый класс: ожидаемая accuracy $\max_c \pi_c$;
- равномерный случайный класс: $\frac{1}{K}$;
- случайный класс с вероятностями π_c: $\sum_c \pi_c^2$.

Эти формулы предполагают те же частоты на новых данных. Большая accuracy константы часто отражает дисбаланс, а не полезную модель. Для квадратичной потери лучший постоянный прогноз — среднее train-таргета; для абсолютной — медиана.

Пример MNIST

Развернуть пиксели в вектор → разделить данные → построить тривиальные и ручные правила → применить kNN → проверить влияние k. Ручной порог яркости центра выделяет отдельные цифры, но не решает всю задачу. Высокое качество kNN на MNIST не гарантирует пригодность для изображений вообще.

EDA: вопросы, а не набор графиков

1. Проверить смысл и типы столбцов, уникальность объектов, ошибки диапазонов, дубликаты.
2. Изучить пропуски: отсутствие может быть самостоятельным сигналом.
3. Посмотреть распределения таргета, дисбаланс классов и групп, редкие категории.
4. Проверить связи признаков с таргетом и друг с другом; сформулировать проверяемые гипотезы.
5. Создать осмысленные признаки: возраст из даты рождения, суммарные расходы, долю скидочных покупок.

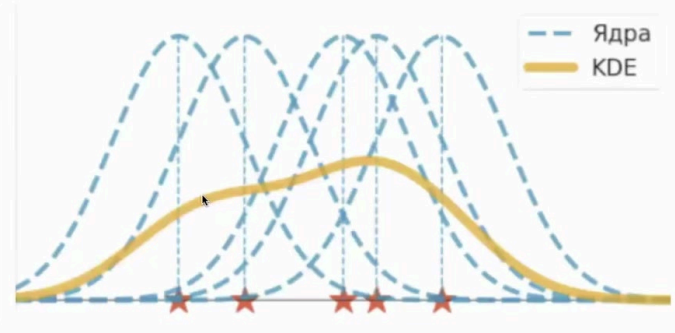
Удаление выброса — решение по смыслу данных, не автоматическая реакция на удалённую точку. Неверный год рождения — ошибка; редкий реальный клиент — часть задачи. Уникальный ID обычно не полезен как числовая координата, но может выявить утечку или дубликаты. Корреляция и хороший прогноз не доказывают причинный эффект.

Ядерная оценка плотности

Для одномерных наблюдений $x_1, \dots, x_n$ и ядра K:

$$\hat{p}_h(t) = \frac{1}{nh} \sum_{i=1}^{n} K\Big(\frac{t - x_i}{h}\Big), \quad h > 0.$$

$K \geq 0$, $\int K(u)\,\mathrm{d}u = 1$; вокруг каждой точки ставится масштабированное ядро, затем вклады усредняются. Это оценка **плотности**, не вероятности в точке. Вероятность интервала — интеграл плотности по интервалу.



Пунктир — вклады отдельных ядер; сплошная линия — их среднее. · 15.09 · 02:45:00

Малое h сохраняет локальные детали и шум; большое h сглаживает, но может скрывать моды. KDE помогает читать распределения на EDA, но сама по себе не объясняет происхождение зависимости.

Практический минимальный протокол

Задача и метрика → разбиение → EDA train → бейзлайн → предобработка → модель → настройка по validation → одна финальная оценка test.

Записывать не только качество, но также время обучения, время предсказания и память. Для реального времени высокая accuracy не компенсирует неприемлемую задержку. Сравнения делать на одном разбиении и одинаковой предобработке; фиксировать случайность, чтобы отделить эффект изменения от случайного разброса.

Перед выводом «модель улучшилась»: проверить отсутствие утечки, правильность метрики, сопоставимость выборок и преимущество над бейзлайном.

02 · Линейная регрессия

22.09.2026 · МНК, интерпретация, оптимизация, статистические свойства.

Линейная регрессия: МНК · 22.09.2026 · Модель и точное решение · Фрагменты: 00:14–00:45; 00:50–00:58.

Что именно линейно

$$f_\theta(x) = x^T\theta, \quad \theta \in \mathbb{R}^d.$$

Линейность относится к **параметрам**, а не обязательно к исходному признаку. Преобразование $\varphi(t) = (1, t, t^2)$ даёт квадратичную зависимость от t, но линейную регрессию по φ. Свободный член включается постоянным признаком $x_0 = 1$ либо выделяется как b.

Для n объектов: $X \in \mathbb{R}^{n\times d}$, $y \in \mathbb{R}^n$, $\hat{y} = X\hat{\theta}$. Здесь d включает постоянный столбец, если он добавлен в X. Для нового объекта x ответ $x^T\hat{\theta}$; для новой матрицы $Z - Z\hat{\theta}$.

Метод наименьших квадратов

Квадратичная потеря $\ell(y, z) = (y - z)^2$ задаёт

$$F(\theta) = \|y - X\theta\|^2 \to \min_\theta.$$

Деление на n не меняет минимум, но меняет масштаб градиента. Раскрываем квадрат:

$$F(\theta) = y^Ty - 2\theta^TX^Ty + \theta^TX^TX\theta.$$

Для столбца v:

$$\nabla_v(a^Tv) = a,$$
$$\nabla_v(v^TAv) = (A + A^T)v.$$

При $A = A^T$ последний градиент равен $2Av$. Поэтому

$$\nabla F = 2X^T(X\theta - y),$$
$$\nabla^2 F = 2X^T X.$$

Матрица $X^T X$ неотрицательно определена:

$$v^T X^T X v = \|Xv\|^2 \geq 0.$$

Функция выпукла; нулевой градиент достаточен для глобального минимума.

Нормальные уравнения

$$X^T X\hat{\theta} = X^T y.$$

При полном столбцовом ранге $\operatorname{rank}(X) = d$:

$$\hat{\theta} = (X^T X)^{-1} X^T y.$$

Тогда минимум единственный. Необходимы $n \geq d$ и отсутствие точной линейной зависимости столбцов. При неполном ранге **МНК не исчезает**: минимум существует, но параметры могут быть неединственны.

> Формула с обратной матрицей — описание решения, а не рекомендация считать обратную явно. Для численного решения предпочтительнее устойчивые методы линейной алгебры.

Прямая с одним признаком

Пусть $f(t) = b + wt$, $\overline{x} = \frac{1}{n}\sum_i x_i$, $\overline{y} = \frac{1}{n}\sum_i y_i$. Из производной по b:

$$\hat{b} = \overline{y} - \hat{w}\overline{x}.$$

Подстановка в loss даёт центрирование:

$$\hat{w} = \frac{\sum_i (x_i - \overline{x})(y_i - \overline{y})}{\sum_i (x_i - \overline{x})^2}.$$

Если все x_i одинаковы, знаменатель нулевой: наклон отдельно не идентифицируется, но оптимальное постоянное предсказание известно. При наличии свободного члена прямая проходит через $(\overline{x}, \overline{y})$.

Геометрия и неединственность

Пространство допустимых обучающих прогнозов — $\mathcal{L} = \{X\theta\}$. МНК выбирает ближайший к y вектор из $\mathcal{L}$: ортогональную проекцию. Остаток $r = y - X\hat{\theta}$ ортогонален каждому столбцу X:

$$X^T r = 0.$$

При неполном ранге различные θ могут задавать одну проекцию:

$$X(\theta + v) = X\theta, \quad v \in \ker X.$$

Обучающие прогнозы единственны, хотя коэффициенты могут быть неединственны. Прогноз вне обучающего пространства тогда также может зависеть от выбранного решения. Псевдообратная матрица X^+ выбирает решение $\hat{\theta} = X^+ y$ минимальной нормы.

Почему kNN здесь может проиграть

kNN хорошо интерполирует локально, но не восстанавливает глобальный линейный закон. Вне диапазона обучения соседи остаются внутри него: среднее не продолжает тренд. Линейная модель экстраполирует, **если выбранная форма зависимости верна**. Это преимущество предположения о структуре, а не гарантия вне данных.

Сложность и ограничения

Для плотной матрицы формирование $X^T X$ стоит $O(nd^2)$, решение системы — порядка $O(d^3)$; прогноз одного объекта — $O(d)$, хранение коэффициентов — $O(d)$. Поэтому МНК удобен при умеренном d, но прямое решение дорого при очень большом d.

Квадратичная потеря сильно штрафует большие остатки: выбросы могут определять решение. Ошибочная форма модели не исправляется точностью оптимизации. Качество обучения и статистические свойства — разные вопросы.

Проверка формул по размерности: $X^T y$ — $d \times 1$, $X^T X$ — $d \times d$, $X\hat{\theta}$ — $n \times 1$.

Признаки, метрики, интерпретация · 22.09.2026 · Практика на страховых расходах · Фрагменты: 01:00–01:50.

Интерпретация коэффициента

При фиксированных остальных координатах

$$f(x + e_j) - f(x) = \theta_j.$$

Это изменение **прогноза**, а не доказанный причинный эффект. Единица коэффициента — единица таргета / единица признака. Сравнивать модули коэффициентов возраста и суммы денег напрямую бессмысленно.

При $z_j = \frac{x_j - \mu_j}{s_j}$ и $f = a + \sum_j \gamma_j z_j$:

$$\theta_j = \frac{\gamma_j}{s_j},$$
$$b = a - \sum_j \gamma_j \frac{\mu_j}{s_j}.$$

γ_j — изменение прогноза при изменении исходного признака на одно стандартное отклонение. В МНК со свободным членом обратимое масштабирование не меняет набор допустимых прогнозов; меняются координаты коэффициентов и численная обусловленность. При регуляризации масштаб уже влияет и на выбранную модель.

Категориальные признаки

Для K категорий one-hot задаёт K индикаторов, сумма которых равна 1. Вместе со свободным членом это точная линейная зависимость. В обычной интерпретируемой параметризации оставить $K - 1$ индикаторов: коэффициенты — различия относительно базовой категории при прочих равных.

`OneHotEncoder(drop="first")` устраняет эту зависимость для линейной модели со сдвигом. Для kNN такое удаление нежелательно: меняет геометрию расстояний между категориями. Категорию нельзя кодировать произвольным числом, если порядок и расстояние не имеют смысла.

Взаимодействия признаков

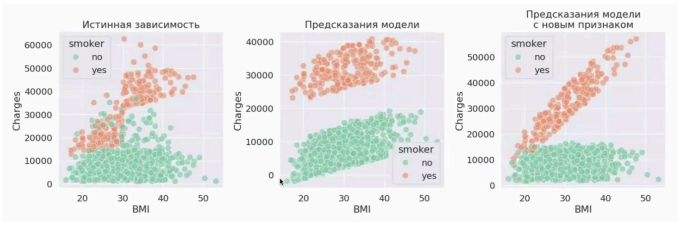
В данных расходов связь с BMI различна для курящих и некурящих. Простая аддитивная модель меняет только сдвиг, но не наклон:

$$f(t, s) = b + at + cs.$$

Добавление произведения ts, где $s \in \{0, 1\}$:

$$f(t, s) = b + at + cs + qts.$$

При $s = 0$: наклон a, сдвиг b. При $s = 1$: наклон $a + q$, сдвиг $b + c$. **Один новый признак меняет смысл сразу нескольких коэффициентов.** Отрицательный c не означает, что курение уменьшает расходы: полный контраст равен $c + qt$.



Данные ⟶ аддитивная модель ⟶ модель с взаимодействием BMI × smoker. · 22.09 · 01:45:00

Метрики регрессии

Для остатков $r_i = y_i - \hat{y}_i$ на проверочной выборке размера m:

$$\mathrm{MSE} = \frac{1}{m}\sum_i r_i^2, \quad \mathrm{RMSE} = \sqrt{\mathrm{MSE}},$$

$$\mathrm{MAE} = \frac{1}{m}\sum_i |r_i|,$$

$$\mathrm{MAPE} = \frac{1}{m}\sum_i \left|\frac{r_i}{y_i}\right|,$$

$$R^2 = 1 - \frac{\sum_i r_i^2}{\sum_i (y_i - \bar{y})^2}.$$

- **MSE:** единицы таргета в квадрате; удобно оптимизировать, чувствительно к большим ошибкам.
- **RMSE:** возвращает единицы таргета, но не равняется средней абсолютной ошибке.
- **MAE:** типичный абсолютный масштаб ошибки; слабее штрафует выбросы.
- **MAPE:** относительная ошибка; для процентов умножить на 100. Не определена при $y_i = 0$, неустойчива около нуля.
- R^2**:** сравнение с постоянным средним **оцениваемой выборки**. Отрицательное значение возможно; оно означает хуже этого среднего.

При постоянном таргете знаменатель R^2 нулевой. Для честного рабочего бейзлайна среднее прогноза берут из train; это не обязательно то же среднее, которое используется в знаменателе test-R^2.

Диагностика перед усложнением

Train и test плохи → проверить признаки, форму зависимости, шум и ошибки данных. Train хорош, test плох → проверять переобучение, утечки и различие распределений. Нельзя считать любую слабую модель переобученной.

Увеличение числа признаков не увеличивает оптимальный **train-SSE** у вложенных МНК-моделей, но может ухудшить test. Полиномиальные признаки повышают выразительность и нестабильность. Взаимодействие, основанное на EDA, часто полезнее механического добавления всех степеней.

> **Коэффициент всегда интерпретируется относительно остальных признаков модели.** После изменения набора признаков прежняя интерпретация может перестать действовать.

Оптимизация и статистические свойства · 22.09.2026 · GD/SGD, Монте-Карло, ковариация, степени свободы · Фрагменты: 01:55–03:05.

Градиентный спуск

Для средней потери $Q(\theta) = \frac{\|X\theta - y\|^2}{n}$:

$$\theta_{t+1} = \theta_t - \eta_t \nabla Q(\theta_t),$$

$$\nabla Q(\theta) = \frac{2}{n} X^T (X\theta - y).$$

Отрицательный градиент — направление локального наискорейшего спуска в евклидовой норме. Слишком большой шаг может привести к расходимости; слишком малый — к медленному обучению. Для квадратичного Q при $L = 2\lambda_{\max}\frac{X^TX}{n}$ постоянный шаг $0 < \eta < \frac{2}{L}$ обеспечивает устойчивость ненулевых спектральных направлений.

Mini-batch SGD

Взять случайные индексы I размера k:

$$g_I(\theta) = \frac{2}{k} X_I^T (X_I\theta - y_I).$$

При равномерной выборке индексов $E[g_I(\theta)] = \nabla Q(\theta)$. Один шаг использует k, а не n объектов; направление шумное, но в среднем соответствует полному градиенту. Для $k = 1$ получаем классический SGD; при $k = n$ — полный градиент.

Стоимость полного шага — $O(nd)$, батча — $O(kd)$. **Итерация** — один шаг; **эпоха** — один проход по обучающим данным. Нельзя сравнивать методы лишь по числу шагов, игнорируя их стоимость. Критерии остановки: изменение loss/параметров, норма градиента, лимит эпох, качество на validation. Для SGD один шумный шаг не доказывает сходимость.

Почему это Монте-Карло

Для независимых Z_i одной природы:

$$A = E[h(Z)], \quad \hat{A} = \frac{1}{k}\sum_{i=1}^{k} h(Z_i).$$

Оценка несмещённа; при конечной дисперсии

$$\mathrm{Var}(\hat{A}) = \frac{\mathrm{Var}(h(Z))}{k}.$$

Стандартное отклонение убывает как $\frac{1}{\sqrt{k}}$. Mini-batch-градиент оценивает среднее по конечной обучающей выборке этим же принципом.

Правила для случайного вектора

Для фиксированной матрицы A и вектора b:

$$E[AZ + b] = AE[Z] + b,$$

$$\mathrm{Cov}(AZ + b) = A\,\mathrm{Cov}(Z)A^T.$$

При нулевом среднем $E\left[\|Z\|^2\right] = \mathrm{tr}(\mathrm{Cov}(Z))$. Эти правила дают свойства МНК без предположения о нормальности шума.

Вероятностная линейная модель

Зафиксировать X полного ранга, $n > d$:

$$y = X\theta_* + \varepsilon, \quad E[\varepsilon] = 0.$$

Эквивалентно можно рассматривать условные моменты при данном X. Тогда

$$\hat{\theta} = \theta_* + (X^TX)^{-1}X^T\varepsilon,$$

$$E[\hat{\theta}] = \theta_*.$$

Это **несмещённость при верной модели и нулевом среднем шума**, а не универсальное свойство любого набора данных.

При $\mathrm{Cov}(\varepsilon) = \sigma^2 I_n$:

$$\mathrm{Cov}(\hat{\theta}) = \sigma^2 (X^TX)^{-1}.$$

Нужны равные дисперсии и отсутствие корреляций ошибок. Независимость достаточна для отсутствия корреляций, но не необходима. При общей $\Sigma = \mathrm{Cov}(\varepsilon)$:

$$\mathrm{Cov}(\hat{\theta}) = A\Sigma A^T,$$

где $A = (X^TX)^{-1}X^T$.

Для нового фиксированного x:

$$E[\hat{f}(x)] = x^T\theta_*,$$

$$\mathrm{Var}(\hat{f}(x)) = \sigma^2 x^T (X^TX)^{-1} x.$$

Это дисперсия **оценки среднего ответа**. Для нового наблюдения с независимым шумом к дисперсии ошибки прогноза добавляется σ^2. Почти вырожденная X^TX даёт большой разброс коэффициентов.

Проекция и остаточная дисперсия

$$H = X(X^TX)^{-1}X^T, \quad \hat{y} = Hy.$$

$H^T = H$, $H^2 = H$, $\mathrm{rank}(H) = \mathrm{tr}(H) = d$. Для $r = (I - H)y = (I - H)\varepsilon$:

$$E[r] = 0, \quad \mathrm{Cov}(r) = \sigma^2(I - H).$$

Поэтому

$$E\left[\|r\|^2\right] = \sigma^2 \operatorname{tr}(I-H) = \sigma^2(n-d).$$

Отсюда несмещённая оценка:

$$\hat{\sigma}^2 = \frac{\left\|y - X\hat{\theta}\right\|^2}{n-d}.$$

d направлений использовано для подгонки модели, осталось $n-d$ степеней свободы. Если сдвиг выделен отдельно и исходных признаков p, знаменатель $n-p-1$.

Не путать: train-MSE делит на n и оценивает шум смещённо вниз; коррекция на степени свободы делит на $n-d$.

03 · Логистическая регрессия

29.09.2026 · Вероятности, ММП, odds ratio, калибровка.

Логистическая регрессия · 29.09.2026 · Вероятности, логит, кросс-энтропия · Фрагменты: 00:27–00:55; 01:53–02:12.

Класс и вероятность — разные ответы

Классификатор $\hat{y} : \mathbb{R}^d \to \{0, \dots, K-1\}$ разбивает пространство на области решений. Вероятностная модель возвращает $\hat{p}_c(x) \geq 0$ с $\sum_c \hat{p}_c(x) = 1$. Для бинарного случая достаточно одного числа $p(x) = P(Y = 1|X = x)$; вероятность класса 0 равна $1 - p(x)$.

Из вероятностей получаем класс $\arg\max_c \hat{p}_c(x)$. Обратное неверно: жёсткая метка не содержит уверенность. Случайность класса отражает шум и ненаблюдаемые факторы, а не только незнание модели.

Линейный логит, нелинейная вероятность

$$z(x) = b + x^T\theta, \quad \sigma(z) = \frac{1}{1+\exp(-z)},$$

$$p_\theta(x) = \sigma(z(x)), \quad Y_i|x_i \sim \operatorname{Bern}(p_\theta(x_i)).$$

Сигмоида монотонна, принимает значения между 0 и 1, $\sigma(0) = \frac{1}{2}$, $\sigma(-z) = 1 - \sigma(z)$.

$$\sigma'(z) = \sigma(z)(1-\sigma(z)).$$

Название «регрессия» связано с моделированием числовой вероятности; итоговая задача может оставаться классификацией.

Для порога $\tau \in (0,1)$:

$$\hat{y}(x) = \mathbb{1}\{p_\theta(x) \geq \tau\},$$

$$p_\theta(x) \geq \tau \Leftrightarrow z(x) \geq \log\left(\frac{\tau}{1-\tau}\right).$$

При $\tau = \frac{1}{2}$ разделяющая поверхность $b + x^T\theta = 0$ — гиперплоскость. Модель линейная по логиту; вероятность не линейна по признакам. После нелинейного преобразования признаков граница может быть нелинейной в исходных координатах.

> **`predict_proba` ≠ `predict`.** Первая операция оценивает вероятность; вторая применяет правило выбора класса. Изменение порога не требует переобучения вероятностной модели.

Accuracy не оценивает уверенность

Прогнозы 0.51 и 0.99 дают одинаковый класс при пороге 0.5, но разные последствия для риска и разные значения вероятностной потери. Высокая accuracy на несбалансированных данных может достигаться константой. В примере дохода нужно сравниваться с большинством классов, а не с 50%.

От правдоподобия к loss

При условной независимости наблюдений и фиксированных x_i:

$$L(\theta) = \prod_{i=1}^{n} p_i^{y_i}(1-p_i)^{1-y_i},$$

где $p_i = \sigma\left(x_i^T\theta\right)$; постоянная координата включена в x_i. Логарифм произведения превращается в сумму:

$$\log L(\theta) = \sum_i [y_i \log p_i + (1-y_i)\log(1-p_i)].$$

Максимизация $\log L$ равна минимизации средней бинарной кросс-энтропии:

$$Q(\theta) = -\frac{1}{n}\sum_i [y_i \log p_i + (1-y_i)\log(1-p_i)].$$

Для отдельного объекта, $z_i = x_i^T\theta$:

$$\ell(y_i, z_i) = \log(1+\exp(z_i)) - y_i z_i.$$

Уверенная ошибка штрафуется сильно: для $y = 1$ и $p \to 0$ потеря $-\log p \to \infty$.

Градиент и выпуклость

По правилу цепочки:

$$\nabla Q(\theta) = \frac{1}{n}\sum_i (p_i - y_i)x_i = \frac{1}{n}X^T(p-y).$$

Для $W = \operatorname{diag}(p_i(1-p_i))$:

$$\nabla^2 Q(\theta) = \frac{1}{n}X^T W X \succcurlyeq 0.$$

Функция выпукла; при полном ранге и конечных параметрах гессиан положительно определён. Но это **не гарантирует существования конечного минимума**. Для полностью разделимых данных масштаб коэффициентов может уходить в бесконечность, а loss стремиться к нулю. Регуляризация ограничивает этот рост.

Закрытого решения обычного вида нет; применяются GD, SGD и более эффективные численные методы. Для батча I:

$$g_I(\theta) = \frac{1}{|I|}X_I^T(p_I - y_I).$$

Размер модели и стоимость прогноза — $O(d)$; сигмоида добавляет лишь скалярную операцию.

Численная устойчивость

Не вычислять наивно $\log(1+\exp(z))$ при большом z:

$$\operatorname{softplus}(z) = \max(z,0) + \log(1+\exp(-|z|)).$$

Вычислять loss по логитам либо использовать устойчивую библиотечную реализацию. Логарифм нулевой численной вероятности — ошибка вычисления, не особенность теории.

Метод максимального правдоподобия · 29.09.2026 · Статистическая основа и примеры · Фрагменты: 00:57–01:53.

Что максимизируется

Наблюдения $Z_1, \dots, Z_n$ независимы и имеют распределение из семейства P_θ. Для непрерывной модели p_θ — плотность, для дискретной — масса вероятности:

$$L(\theta; z) = \prod_i p_\theta(z_i),$$

$$\hat{\theta} \in \arg\max_\theta L(\theta; z).$$

В правдоподобии **данные фиксированы**, меняется параметр. L не является распределением вероятности по θ. Значение плотности в точке не является вероятностью этой точки.

Если $L > 0$, монотонность логарифма сохраняет максимум:

$$\ell(\theta) = \log L(\theta) = \sum_i \log p_\theta(z_i).$$

Можно отбросить только слагаемые, не зависящие от **оцениваемого** параметра. Уравнение $\nabla\ell = 0$ —

условие внутренней стационарной точки, не универсальный способ найти максимум. Проверять область параметров и границы.

Нормальное распределение

$$Z_i \sim \mathcal{N}(\mu, \sigma^2).$$

Лог-правдоподобие с точностью до константы:

$$\ell(\mu, \sigma^2) = -\frac{n}{2}\log\sigma^2 - \frac{\sum_i (z_i - \mu)^2}{2\sigma^2}.$$

Производная по μ даёт

$$\hat{\mu} = \bar{z} = \frac{1}{n}\sum_i z_i.$$

Если σ^2 тоже неизвестна:

$$\hat{\sigma}^2_{\text{MLE}} = \frac{1}{n}\sum_i (z_i - \bar{z})^2.$$

Это ММП-оценка, **смещённая вниз** при конечном n. Несмещённая оценка использует знаменатель $n-1$. Если среднее известно заранее, коррекция на оценку среднего не нужна.

Свойства не бесплатны

При условиях регулярности и идентифицируемости ММП-оценки часто состоятельны, асимптотически нормальны и эффективны. Это асимптотические утверждения с предпосылками; они не обещают несмещённость на маленькой выборке или единственность любого найденного корня.

Несмещённость: $E[\hat{\theta}] = \theta$. **Состоятельность:** $\hat{\theta}_n \to \theta$ по вероятности. Одно свойство не заменяет другое; меньшая дисперсия иногда важнее небольшого смещения.

МНК как ММП

При фиксированном X:

$$y = X\theta + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2 I_n).$$

Тогда условная плотность y:

$$L(\theta, \sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left(-\frac{\|y - X\theta\|^2}{2\sigma^2}\right).$$

Для фиксированного σ^2 максимизация по θ равна минимизации SSE:

$$\hat{\theta}_{\text{MLE}} = (X^T X)^{-1} X^T y.$$

Если одновременно оценивать шум:

$$\hat{\sigma}^2_{\text{MLE}} = \frac{\left\|y - X\hat{\theta}\right\|^2}{n}.$$

Несмещённая оценка из предыдущей лекции делит на $n - d$. Нормальный шум объясняет квадратную потерю через ММП; несмещённость МНК сама по себе не требует нормальности.

Бернулли: частота как оценка

$$Z_i \sim \text{Bern}(\theta), \quad \theta \in [0, 1].$$

$$p_\theta(z) = \theta^z (1-\theta)^{1-z}.$$

Пусть $s = \sum_i z_i$:

$$L(\theta) = \theta^s (1-\theta)^{n-s},$$

$$\ell'(\theta) = \frac{s}{\theta} - \frac{n-s}{1-\theta}.$$

Для $0 < s < n$ получаем $\hat{\theta} = \frac{s}{n}$. При всех нулях или единицах максимум на границе: 0 или 1. Логистическая регрессия заменяет одну общую вероятность на $\sigma(x_i^T\theta)$ для каждого объекта.

Равномерное распределение: граница

$$Z_i \sim \text{U}([0, \theta]), \quad \theta > 0.$$

В выбранной версии плотности

$$L(\theta) = \theta^{-n}\mathbb{1}\left\{\theta \geq \max_i z_i\right\}.$$

В допустимой области правдоподобие убывает, поэтому

$$\hat{\theta}_{\text{MLE}} = \max_i z_i.$$

Производная внутри области не равна нулю в максимуме. Носитель зависит от параметра; стандартные регулярные аргументы нельзя переносить автоматически.

> **Шаблон вывода:** семейство и область параметров → плотность/масса → произведение → логарифм → оптимизация с проверкой границ → свойства оценки и их предпосылки.

Интерпретация и калибровка · 29.09.2026 · Доход, пропуски, кредитный риск · Фрагменты: 02:12–02:35; 02:40–03:06.

Odds ratio вместо «прироста вероятности»

Для $p = \sigma(b + x^T\theta)$:

$$\frac{p}{1-p} = \exp(b + x^T\theta),$$

$$\log\left(\frac{p}{1-p}\right) = b + x^T\theta.$$

Шансы $\frac{p}{1-p}$ — отношение вероятностей классов 1 и 0, не сама вероятность. При увеличении x_j на Δ и фиксированных прочих признаках:

$$\frac{\text{odds}(x + \Delta e_j)}{\text{odds}(x)} = \exp(\theta_j \Delta).$$

$\exp(\theta_j)$ — мультипликативный эффект единичного изменения на шансы. Коэффициент 0.7 умножает шансы примерно на 2, **не прибавляет 70 процентных пунктов**.

$$\frac{\partial p}{\partial x_j} = \theta_j p(1-p).$$

Изменение вероятности зависит от начального p. Например, удвоение шансов переводит $p = 0.1$ в 0.182, а $p = 0.5$ в 0.667. Все интерпретации условны на остальные признаки; коррелированные признаки и взаимодействия изменяют смысл коэффициентов.

Предобработка практического примера

Числовые признаки — стандартизировать; категории — one-hot; пропуски — заполнять по статистикам train: медиана / наиболее частое значение или осмысленная отдельная категория. Удаление всех объектов с пропусками — простой бейзлайн, но меняет состав выборки.

Для линейной модели со сдвигом исключение одной one-hot-категории устраняет точную зависимость. Нелинейные признаки (квадраты, произведения) могут улучшить форму логита, но требуют внешней проверки качества.

Локальная проверка формы зависимости

Ядерное сглаживание бинарного таргета по одному признаку:

$$\widehat{m}_h(t) = \frac{\sum_i K\left(\frac{t - x_i}{h}\right) y_i}{\sum_i K\left(\frac{t - x_i}{h}\right)}.$$

Это оценка локальной частоты класса, не KDE-плотность. Используется для сопоставления формы данных с прогнозами. Одномерная зависимость усредняет остальные признаки; она не равна частному эффекту при фиксированных остальных координа-

тах. В областях с малым количеством объектов вывод ненадёжен.

Решение по стоимости ошибок

Если C_{FP} — цена ложного класса 1, а C_{FN} — ложного класса 0, выбирать 1 при $C_{FP}(1-p) \le C_{FN}p$:

$$\tau = \frac{C_{FP}}{C_{FP} + C_{FN}}.$$

Это следствие минимизации ожидаемых затрат; порог 0.5 оправдан лишь при равных ценах.

Что означает калибровка

Идеальная калибровка:

$$E[Y \mid \hat{p}(X)] = \hat{p}(X) \quad \text{почти наверное.}$$

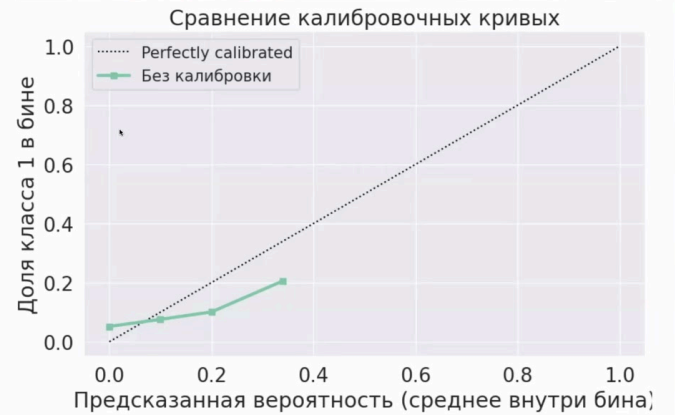
Эквивалентный смысл: среди объектов с прогнозом около 0.2 доля класса 1 должна быть около 20%. Точное равенство непрерывного score одному числу нельзя проверять простой частотой: на практике используют бины или сглаживание.

Для бина B_j и индексов $I_j = \{i : \hat{p}(x_i) \in B_j\}$:

$$\overline{p}_j = \frac{1}{|I_j|} \sum_{i \in I_j} \hat{p}(x_i),$$

$$\overline{y}_j = \frac{1}{|I_j|} \sum_{i \in I_j} y_i.$$

Калибровочная кривая соединяет $(\overline{p}_j, \overline{y}_j)$. Идеал — диагональ. По оси x именно **средняя предсказанная вероятность**, а не доля объектов, попавших в бин.



Фактическая доля класса 1 против среднего score в бине. · 29.09 · 03:04:20

Выше диагонали → риск класса 1 недооценён; ниже → переоценён. Смотреть число объектов в каждом бине: маленький бин даёт шумную частоту. Результат зависит от разбиения; одна кривая не является точным доказательством качества.

Калибровка не равна различению

Постоянный прогноз частоты класса может быть хорошо калиброван, но не различать объекты. Хороший классификатор, наоборот, может выдавать плохие вероятности. Для кредита или медицинского риска нужны и различение, и достоверные вероятности.

Как обучать калибратор

Train → обучить модель; calibration → обучить преобразование score; test → проверить результат. Либо использовать корректную cross-validation-схему.

Платт: сигмоидальное преобразование score s: $\sigma(as + b)$. **Изотоническая регрессия:** гибкое монотонное преобразование; требует больше данных и может переобучиться на малой калибровочной выборке. Нельзя обучать калибратор и оценивать его на тех же объектах. Даже логистическая форма сама по себе не гарантирует калибровку на новых данных.

04 · Польза регуляризации

06.10.2026 · Ridge, Lasso, коллинеарность, проксимальные методы.

Регуляризация: Ridge · 06.10.2026 · Центрирование, решение, смещение–дисперсия · Фрагменты: 00:02–01:00.

Зачем штрафовать параметры

Полином высокой степени может идеально пройти через несколько зашумлённых точек, но сильно колебаться между ними и вне обучающего диапазона. Большие компенсирующие коэффициенты — один из признаков нестабильности, **не универсальное доказательство переобучения**. Масштаб коэффициента зависит от единицы измерения признака.

Регуляризация ограничивает гибкость, сохраняя выбранное семейство модели:

$$F(\theta) + \lambda R(\theta) \to \min_{\theta}, \quad \lambda \ge 0.$$

Здесь $F = \|y - X\theta\|^2$ — **сумма**, не средняя потеря. Деление всего функционала на n не меняет решение; деление только data-loss изменяет относительный штраф.

> Ниже Ridge: $R(\theta) = \|\theta\|^2$; Lasso: $R(\theta) = \|\theta\|_1$. Для записи $\frac{F}{2n} + \alpha R$ соответствие $\lambda = 2n\alpha$. Значения параметра нельзя переносить между разными нормировками без пересчёта.

Свободный член не штрафуется

$$F(b, \theta) = \|y - b\mathbb{1} - X\theta\|^2 + \lambda\|\theta\|^2.$$

Производная по b даёт

$$\hat{b} = \overline{y} - \overline{x}^T\hat{\theta}.$$

Центрировать $X_c = X - \mathbb{1}\overline{x}^T$, $y_c = y - \overline{y}\mathbb{1}$:

$$\hat{\theta} = \arg\min_{\theta} \left[\|y_c - X_c\theta\|^2 + \lambda\|\theta\|^2\right].$$

Статистики центрирования берутся по train; новый прогноз остаётся $\hat{b} + x^T\hat{\theta}$. Штраф на свободный член сделал бы ответ зависимым от произвольного сдвига таргета.

Точное решение Ridge

Далее X, y считаются центрированными; $A = X^TX$.

$$\nabla F = 2X^T(X\theta - y) + 2\lambda\theta.$$

$$(A + \lambda I)\hat{\theta} = X^Ty,$$

$$\hat{\theta}_\lambda = (A + \lambda I)^{-1}X^Ty.$$

При $\lambda > 0$ матрица положительно определена даже при вырожденном A:

$$v^T(A + \lambda I)v = \|Xv\|^2 + \lambda\|v\|^2 > 0.$$

Для штрафуемых коэффициентов решение единственно.

Что происходит при изменении λ

При $\lambda \to 0$ и обратимой A получаем МНК. Для вырожденной A предел выбирает МНК-решение минимальной нормы. При $\lambda \to \infty$ штрафуемые коэффициенты стремятся к 0, свободный член — к $\overline{y}$: прогноз становится константным. Увеличивать штраф бесконечно не означает улучшать качество бесконечно.

Пусть $A = V\,\mathrm{diag}(s_j)V^T$, $s_j \ge 0$. В невырожденных направлениях Ridge сжимает коэффициенты МНК множителем

$$\frac{s_j}{s_j + \lambda}.$$

Малые s_j — слабые направления данных — подавляются сильнее. При $\lambda > 0$ обусловленность системы улучшается:

$$\kappa(A + \lambda I) = \frac{s_{\max} + \lambda}{s_{\min} + \lambda}.$$

Цена устойчивости: смещение

Для верной модели $y = X\theta_* + \varepsilon$, $E[\varepsilon] = 0$, $\mathrm{Cov}(\varepsilon) = \sigma^2 I$ и $G = A + \lambda I$:

$$E\big[\hat{\theta}_\lambda\big] = G^{-1}A\theta_*,$$
$$\mathrm{Bias} = -\lambda G^{-1}\theta_*,$$
$$\mathrm{Cov}\big(\hat{\theta}_\lambda\big) = \sigma^2 G^{-1}AG^{-1}.$$

В направлении $s_j > 0$ дисперсия вместо $\frac{\sigma^2}{s_j}$ равна

$$\sigma^2 \frac{s_j}{\big(s_j + \lambda\big)^2}.$$

Она меньше, но появляется смещение. Центрирование со свободным членом требует рассматривать шум после соответствующей проекции; для ковариации коэффициентов формула сохраняется, поскольку $X_c^T \mathbb{1} = 0$.

Смещение–дисперсия прогноза

Пусть $f_*(x) = E[Y|X = x]$, новый шум независим от обучающей выборки D. Тогда при фиксированном x:

$$E\Big[\big(Y - \hat{f}_D(x)\big)^2\Big] = \sigma^2(x) + \mathrm{Bias}(x)^2 + \mathrm{Var}_D\big(\hat{f}_D(x)\big).$$

Первый член — неустранимый шум, второй — ошибка средней модели, третий — разброс модели при смене обучающей выборки. Регуляризация часто уменьшает третий ценой второго; суммарная ошибка может снизиться, но это не гарантировано для любого λ.

Выбор λ: по validation/CV, вместе с предобработкой, а не по минимальному train-loss. Сравнивать с МНК и константой на одном разбиении.

Lasso, геометрия и коллинеарность · 06.10.2026 · Разреженность, ElasticNet, коэффициенты, VIF · Фрагменты: 01:00–02:20.

Lasso и точные нули

Для центрированных данных:

$$\hat{\theta} = \arg\min_\theta \Big[\|y - X\theta\|^2 + \lambda\|\theta\|_1\Big].$$

$\|\theta\|_1 = \sum_j |\theta_j|$. При $\theta_j \neq 0$ производная штрафа — $\lambda\,\mathrm{sign}(\theta_j)$; в нуле обычная производная не существует. Условие оптимальности использует субдифференциал, а не произвольное значение sign(0).

Для остатка $r = y - X\hat{\theta}$ и столбца X_j:

$$2X_j^T r = \begin{cases} \lambda\,\mathrm{sign}(\hat{\theta}_j) & \hat{\theta}_j \neq 0 \\ \text{число из } [-\lambda, \lambda] & \hat{\theta}_j = 0 \end{cases}.$$

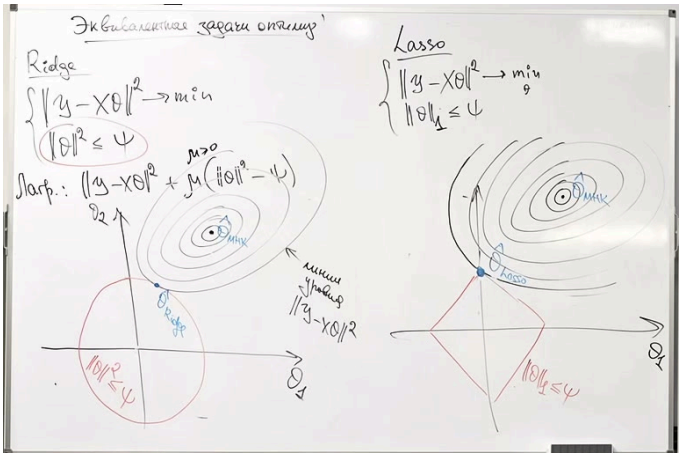
Следовательно, нулевой коэффициент возможен, когда абсолютная корреляция остатка с признаком достаточно мала: $\big|2X_j^T r\big| \le \lambda$. При $\lambda \ge 2\big\|X^T y\big\|_\infty$ нулевой вектор удовлетворяет условиям оптимальности.

Геометрическая причина разреженности

Штрафованные задачи связаны с ограниченными:

$$\min_\theta \|y - X\theta\|^2 \quad \text{при } R(\theta) \le c.$$

Для соответствующих c и множителя Лагранжа λ решения совпадают; это не означает $c = \lambda$. Линии уровня data-loss касаются допустимой области. Шар L_2 гладкий; шар L_1 имеет углы на осях, где некоторые координаты равны нулю.



Ridge: круг; Lasso: ромб. Касание угла даёт нулевую координату. · 06.10 · 01:35:00

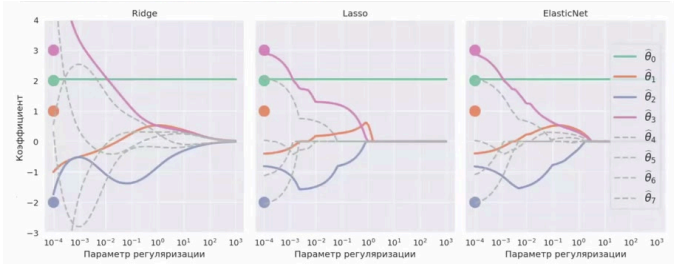
Ridge обычно сжимает без точного отбора; **Lasso** может обнулить признаки. Геометрия объясняет тенденцию, но не гарантирует правильный набор существенных признаков.

ElasticNet и масштаб

$$F(\theta) = \|y - X\theta\|^2 + \lambda_1\|\theta\|_1 + \lambda_2\|\theta\|^2.$$

Сочетает разреженность L_1 и устойчивость L_2. При $\lambda_2 > 0$ функционал строго выпуклый по штрафуемым коэффициентам. При коррелированных признаках Lasso может выбирать один вместо другого; Ridge распределяет вклад более плавно, ElasticNet сочетает эффекты.

Стандартизировать числовые признаки до штрафа: иначе цена одинакового влияния на прогноз зависит от выбранной единицы измерения. Сначала масштабировать train, затем применять те же статистики к остальным данным. One-hot и свободный член требуют осмысленного выбора параметризации и штрафов.



Траектории коэффициентов: Ridge, Lasso, ElasticNet; свободный член не штрафуется. · 06.10 · 01:45:20

Уменьшение нормы при усилении штрафа не означает монотонного уменьшения **каждого** модуля коэффициента: признаки могут перераспределять вклад. При смене λ отдельный коэффициент способен менять знак или временно расти.

Мультиколлинеарность

Если столбцы линейно зависимы, $X^T X$ вырождена; если почти зависимы — плохо обусловлена. Например, копии признаков либо бухгалтерское тождество «прибыль = выручка − затраты». Даже при хорошем прогнозе коэффициенты могут быть огромны, нестабильны и плохо интерпретируемы. Малые возмущения данных существенно меняют их, потому что близкие признаки компенсируют друг друга.

Попарная корреляция не обнаруживает все зависимости: один столбец может выражаться через **несколько** других. Для каждого j регрессировать X_j на остальные признаки:

$$\mathrm{VIF}_j = \frac{1}{1 - R_j^2}.$$

R_j^2 — качество восстановления **признака**, не предсказания таргета. Большой VIF указывает на коллинеарность; порог — эвристика. Высокий VIF не означает сам по себе ненужность признака.

В примере Всемирного банка агрегаты регионов пересекаются с данными стран. Разнос связанных наблюдений по train/test может создать утечку. Плохое R^2 МНК при хороших отдельных признаках — повод проверить структуру данных и устойчивость.

Субградиенты и проксимальный шаг · 06.10.2026 · Почему Lasso обнуляет коэффициенты · Фрагменты: 02:22–02:59.

Субдифференциал выпуклой функции

Для выпуклой $f : \mathbb{R}^d \to \mathbb{R}$ вектор g — субградиент в x_0, если

$$f(x) \geq f(x_0) + g^T(x - x_0) \quad \forall x.$$

Правая часть — опорная гиперплоскость, лежащая не выше графика. Множество таких g обозначают $\partial f(x_0)$. При дифференцируемости оно состоит из одного градиента.

Для модуля:

$$\partial |x| = \begin{cases} \{1\} & x > 0 \\ \{-1\} & x < 0. \\ [-1, 1] & x = 0 \end{cases}$$

В нуле все наклоны от -1 до 1 задают опорные прямые. Для $\|\theta\|_1$ субдифференциал задаётся покоординатно.

Критерий минимума выпуклой функции:

$$x_* \in \arg\min f \Leftrightarrow 0 \in \partial f(x_*).$$

Если нулевой вектор — субградиент, неравенство определения сразу даёт $f(x) \geq f(x_*)$. Обратное следует из того же неравенства с $g = 0$.

Проксимальный оператор

Для выпуклого штрафа R и $a > 0$:

$$\mathrm{prox}_{aR}(v) = \arg\min_u \left[\frac{1}{2}\|u - v\|^2 + aR(u) \right].$$

Это компромисс: остаться рядом с v и уменьшить штраф. Квадратичный член делает задачу строго выпуклой, поэтому решение единственно для обычных замкнутых выпуклых штрафов. Условие оптимальности:

$$0 \in u - v + a\partial R(u),$$
$$v - u \in a\partial R(u).$$

Минимум как неподвижная точка

Для гладкой выпуклой F и выпуклой R:

$$0 \in \nabla F(\theta_*) + \lambda \partial R(\theta_*).$$

Подставить $v = \theta_* - \eta \nabla F(\theta_*)$, $a = \eta\lambda$:

$$\theta_* = \mathrm{prox}_{\eta\lambda R}(\theta_* - \eta \nabla F(\theta_*)).$$

Это условие оптимальности, а не ещё готовое закрытое решение; оно подсказывает итерационный алгоритм.

Мягкое пороговое отсечение

Для одномерного $R(u) = |u|$ решить

$$\min_u \left[\frac{1}{2}(u - v)^2 + a|u| \right].$$

1. $u > 0$: $u - v + a = 0$, значит $u = v - a$, допустимо при $v > a$.
2. $u < 0$: $u - v - a = 0$, значит $u = v + a$, допустимо при $v \leftarrow a$.
3. $u = 0$: $0 \in -v + a[-1, 1]$, значит $|v| \leq a$.

Итак,

$$S_a(v) = \begin{cases} v - a & v > a \\ 0 & |v| \leq a. \\ v + a & v \leftarrow a \end{cases}$$

$$S_a(v) = \mathrm{sign}(v) \max(|v| - a, 0).$$

Для вектора оператор применяется независимо к координатам. **Точное обнуление** следует из интервала субградиентов в нуле; это не округление маленького коэффициента.

Проксимальный градиент для Lasso

При $F(\theta) = \|y - X\theta\|^2$:

$$v_t = \theta_t - 2\eta X^T(X\theta_t - y),$$
$$\theta_{t+1} = S_{\eta\lambda}(v_t).$$

Сначала обычный градиентный шаг по гладкой части, затем soft-thresholding. Свободный член, если выделен, обновляется **без** порогового отсечения. Для $L = 2\lambda_{\max}(X^TX)$ безопасный выбор $0 < \eta \leq \frac{1}{L}$; при иных нормировках loss пересчитываются и шаг, и порог.

Для ортонормированных столбцов $X^TX = I$ задача разделяется:

$$\hat{\theta} = S_{\frac{\lambda}{2}}(X^Ty).$$

Множитель $\frac{1}{2}$ здесь появился из выбранного **SSE**, а не $\frac{\mathrm{SSE}}{2}$. Для общего X нельзя просто применить этот порог к МНК-коэффициентам.

Почему не обычный градиент штрафа

У L_1 нет единственного градиента в нуле. Субградиентный шаг возможен, но может колебаться около нуля; проксимальный шаг решает негладкую часть точно. Для L_2 же проксимальный оператор — непрерывное сжатие:

$$\mathrm{prox}_{a\|\cdot\|^2}(v) = \frac{v}{1 + 2a}.$$

> **Контроль перед применением:** масштаб признаков; штрафуемые координаты; нормировка loss; соответствие λ; устойчивость по разбиениям; качество и интерпретируемость на новых данных.